



INSTITUTO FEDERAL

Santa Catarina
Campus São José

MINISTÉRIO DA EDUCAÇÃO
SECRETARIA DE EDUCAÇÃO PROFISSIONAL E TECNOLÓGICA
INSTITUTO FEDERAL DE SANTA CATARINA
CAMPUS SÃO JOSÉ

ICD - INTRO. À CIÊNCIA DE DADOS E APRENDIZADO DE MÁQUINA

PARTE 2: Análise de Requisitos e Preparação de Dados

Prof. Ramon Mayor Martins, Dr.

[ramon.mayor at: ifsc.edu.br](mailto:ramon.mayor@ifsc.edu.br)

Apresentação
Disponível em:

Agenda da Parte 2

- ❑ Análise de Requisitos em Projetos de ML
- ❑ Coleta de Dados e Fontes de Datasets
- ❑ Tipos de Dados e Estruturas
- ❑ Exploração e Análise Descritiva
- ❑ Preparação e Limpeza de Dados
- ❑ Ferramentas Python para Ciência de Dados
- ❑ Prática com Datasets Reais

Processo de Desenvolvimento de Modelo de Machine Learning





Etapa 1 - Análise de Requisitos


Análise de Requisitos: Introdução

- ❑ A análise de requisitos é a primeira etapa crítica em qualquer projeto de Machine Learning.
- ❑ Envolve compreender o problema de negócio e definir objetivos claros
- ❑ Para atingir os critérios de sucesso do modelo.


Análise de Requisitos: Componentes

- ❑ Definição do Problema: O que queremos resolver?
- ❑ Tipo de Tarefa: Classificação, Regressão, Clustering?
- ❑ Dados Disponíveis: Que dados temos ou podemos obter?
- ❑ Métricas de Sucesso: Como mediremos o desempenho?
- ❑ Restrições: Tempo, recursos, precisão mínima

Análise de Requisitos: Tarefas de ML




Análise de Requisitos: Tarefas de ML



Análise de Requisitos: Definindo Métricas de Sucesso

A Métrica de sucesso vai depender do tipo de tarefa

- ❑ Classificação: Acurácia, Precisão, Recall, F1-Score
- ❑ Detecção de objeto: IoU (Intersection over Union)
- ❑ Regressão: MAE, MSE, RMSE, R^2
- ❑ Clustering: Silhouette Score, Inércia



Análise de Requisitos: Definindo Métricas de Sucesso


Métricas básicas:

		Predicted	
		Negative (N) -	Positive (P) +
Actual	Negative -	True Negative (TN)	False Positive (FP) Type I Error
	Positive +	False Negative (FN) Type II Error	True Positive (TP)

Accuracy	Predictions/ Classifications	$\frac{\text{Correct}}{\text{Correct} + \text{Incorrect}}$
Precision	Predictions/ Classifications	$\frac{\text{True Positive}}{\text{True Positive} + \text{False Positive}}$
Recall	Predictions/ Classifications	$\frac{\text{True Positive}}{\text{True Positive} + \text{False Negative}}$
F1	Predictions/ Classifications	$\frac{2 * \text{True Positive}}{\text{True Positive} + 0.5 (\text{False Positive} + \text{False Negative})}$
IoU	Object Detections/ Segmentations	$\frac{\text{Pixel Overlap}}{\text{Pixel Union}}$ 


Análise de Requisitos: Exemplo de Análise de Requisito

- ❑ Problema: Classificação automática de imagens médicas (normal vs. anormal)
- ❑ Tipo: Sistema de classificação de imagens
- ❑ Dados: Banco de imagens rotuladas (ex.: raio-X, mamografia)
- ❑ Métrica: Acurácia (**95%**) e F1-Score na predição das classes
- ❑ Restrição: Treinamento em GPU disponível e tempo de inferência < 200ms por imagem



Análise de Requisitos: Exemplo de Análise de Requisito

- ❑ Problema: Identificar espécies de plantas a partir de fotos de folhas
- ❑ Tipo: Sistema de classificação de imagens
- ❑ Dados: Banco de imagens rotuladas de folhas (espécies diferentes, ângulos variados)
- ❑ Métrica: Acurácia (**75%**) nas predições
- ❑ Restrição: Funcionar em dispositivos móveis (limite de memória < 200 MB, inferência < 500ms)






Etapa 2 - Preparação de Dados

Preparação de Dados: Fonte de Dados

- ❑ Dados Internos: Sistemas da empresa, logs, transações
- ❑ Dados Públicos: Governamentais, pesquisas acadêmicas (Ciência Aberta)
- ❑ APIs: Redes sociais, serviços web
- ❑ Web Scraping: Extração de dados de websites
- ❑ Datasets Prontos: Kaggle, UCI ML Repository



Preparação de Dados: Fonte de Dados

- ❑ Dados Internos: Sistemas da empresa, logs, transações
- ❑ Dados Públicos: Governamentais, pesquisas acadêmicas (Ciência Aberta)
- ❑ APIs: Redes sociais, serviços web
- ❑ Web Scraping: Extração de dados de websites
- ❑ Datasets Prontos: Kaggle, UCI ML Repository

kaggle PhysioNet 



<https://github.com/public-apis/public-apis?tab=readme-ov-file>




Preparação de Dados: Fonte de Dados

- ❑ Principais Repositórios de Datasets
 - ❑ Kaggle: Competições e datasets variados
 - ❑ UCI ML Repository: Datasets clássicos para aprendizado
 - ❑ Google Dataset Search: Motor de busca para datasets
 - ❑ AWS Open Data: Dados públicos na nuvem
 - ❑ PhysioNet: Dados médicos e fisiológicos
 - ❑ GitHub: Repositórios com datasets específicos



Clique nas imagens

kaggle

PhysioNet 



aws open
data


Preparação de Dados: Fonte de Dados

- ❏ Principais Repositórios de Datasets
 - ❏ Kaggle: Competições e datasets variados, ex: Iris dataset



Clique nas imagem

kaggle




Preparação de Dados: Fonte de Dados

- ❑ Principais Repositórios de Datasets
 - ❑ Kaggle: Competições e datasets variados, ex: Mini Dogs and Cats dataset



Clique nas imagem

kaggle

A screenshot of the Kaggle dataset page for 'Mini-Dogs-And-Cats'. The page shows the dataset title, a description, and a grid of 10 sample images. The dataset is created by Eduardo de Andrade Nogueira and is updated 4 years ago. It has a usability score of 6.25 and is licensed under CC0: Public Domain. The dataset contains 10 files, all named 'cat' followed by a number in parentheses and '.jpg'. The files are displayed in a grid of 2 rows and 5 columns. Each file has a thumbnail image and its name and size. The files are: cat (1).jpg (554.73 kB), cat (10).jpg (539.17 kB), cat (2).jpg (588.09 kB), cat (3).jpg (677.21 kB), cat (4).jpg (1.46 MB), cat (5).jpg (1.95 MB), cat (6).jpg (2.17 MB), cat (7).jpg (3.35 MB), cat (8).jpg (1.39 MB), and cat (9).jpg (236.73 kB).

EDUARDO DE ANDRADE NOGUEIRA · UPDATED 4 YEARS AGO

Mini-Dogs-And-Cats
dataset containing public domain cats and dogs photos

Data Card Code (4) Discussion (0) Suggestions (0)

About Dataset
No description available

Usability 6.25

License
CC0: Public Domain

Expected update frequency
Not specified

cat (10 files)

File Name	Size
cat (1).jpg	554.73 kB
cat (10).jpg	539.17 kB
cat (2).jpg	588.09 kB
cat (3).jpg	677.21 kB
cat (4).jpg	1.46 MB
cat (5).jpg	1.95 MB
cat (6).jpg	2.17 MB
cat (7).jpg	3.35 MB
cat (8).jpg	1.39 MB
cat (9).jpg	236.73 kB

Preparação de Dados: Tipos de Dados

- ❑ Estruturados (Categórico): Tabelas com linhas e colunas
- ❑ Semi-estruturados: JSON, XML
- ❑ Não-estruturados: Texto, imagens, áudio, vídeo
- ❑ Temporais: Séries temporais
- ❑ Geoespaciais: Dados com localização

Q Search

▼ 38 Code Download

IRIS DATASET

The Iris Dataset contains four features (length and width of sepals and petals)

Data Card Code (11) Discussion (0) Suggestions (0)

About Dataset

Usability 10.00
License Other (specified in description)
Expected update frequency Never

The Iris Dataset contains four features (length and width of sepals and petals) of 50 samples of three species of Iris (Iris setosa, Iris virginica and Iris versicolor).

# sepal-length sepal-length	# sepal-width sepal-width	# petal-length petal-length	# petal-width petal-width	Δ species species
				3 unique values
4.3	2	1	0.1	Iris-setosa
7.9	4.4	6.9	2.5	Iris-setosa
5.1	3.5	1.4	0.2	Iris-setosa
4.9	3	1.4	0.2	Iris-setosa
4.7	3.2	1.3	0.2	Iris-setosa
4.6	3.1	1.5	0.2	Iris-setosa
5	3.6	1.4	0.2	Iris-setosa

ESLIARDO DE ANDRADE RODRIGUES · UPDATED 4 YEARS AGO

▼ 1 Code Download

Mini-Dogs-And-Cats

dataset containing public domain cats and dogs photos

Data Card Code (4) Discussion (0) Suggestions (0)

About Dataset

Usability 4.50
License CC0 Public Domain
Expected update frequency Not specified

No description available

cat (10 files)


 cat (1).jpg 554.73 kB	 cat (10).jpg 538.17 kB	 cat (2).jpg 588.09 kB	 cat (3).jpg 677.21 kB	 cat (4).jpg 1.46 MB
 cat (5).jpg 1.95 MB	 cat (6).jpg 2.17 MB	 cat (7).jpg 3.35 MB	 cat (8).jpg 1.39 MB	 cat (9).jpg 238.73 kB

Preparação de Dados: Tipos de Dados

CONTRAPARTIDA: DATASET NÃO ESTRUTURADO vs. DATASET ESTRUTURADO



VS



Preparação de Dados: Tipos de Dados

Estruturados: Tabelas com linhas e colunas

 Search

 VIJAYARATHYAN V.G · UPDATED 3 YEARS AGO

 38   

IRIS DATASET

The Iris Dataset contains four features (length and width of sepals and petals)



[Data Card](#) [Code \(11\)](#) [Discussion \(0\)](#) [Suggestions \(0\)](#)

About Dataset

The Iris Dataset contains four features (length and width of sepals and petals) of 50 samples of three species of Iris (Iris setosa, Iris virginica and Iris versicolor).

Usability 
10.00

License
Other (specified in description)

Expected update frequency
Never

# sepal-length	# sepal-width	# petal-length	# petal-width	Δ species
sepal-length	sepal-width	petal-length	petal-width	species
				3 unique values
4.3	2	1	0.1	Iris-setosa
5.1	3.5	1.4	0.2	Iris-setosa
4.9	3	1.4	0.2	Iris-setosa
4.7	3.2	1.3	0.2	Iris-setosa
4.6	3.1	1.5	0.2	Iris-setosa
5	3.6	1.4	0.2	Iris-setosa

Preparação de Dados: Tipos de Dados

❏ Estruturados: Tabelas com linhas e colunas



[Clique para acessar o Notebook 1 no Google Colab](#)

iris setosa



petal sepal

iris versicolor




petal sepal

iris virginica



petal sepal

Supervised learning *classification* problem
(using the [Iris flower data set](#))



Training / test data

Features Labels

Sepal length	Sepal width	Petal length	Petal width	Species
5.1	3.5	1.4	0.2	Iris setosa
4.9	3.0	1.4	0.2	Iris setosa
7.0	3.2	4.7	1.4	Iris versicolor
6.4	3.2	4.5	1.5	Iris versicolor
6.3	3.3	6.0	2.5	Iris virginica
5.8	3.3	6.0	2.5	Iris virginica

Preparação de Dados: Qualidade dos Dados

- ❑ A qualidade dos dados determina o sucesso do modelo.
- ❑ "*Garbage in, garbage out*" - dados ruins resultam em modelos ruins.
- ❑ Regras da Qualidade de dados



Preparação de Dados: Qualidade dos Dados

Accuracy (Acurácia)

O dado representa corretamente a realidade.

Ex. Se uma imagem é de um gato, mas no dataset está rotulada como cachorro, temos um problema de acurácia. Isso gera erros no treinamento do modelo.



Preparação de Dados: Qualidade dos Dados

Accuracy (Acurácia)

O dado representa corretamente a realidade.

Ex. Se uma imagem é de um gato, mas no dataset está rotulada como cachorro, temos um problema de acurácia. Isso gera erros no treinamento do modelo.

Completeness (Completeness)

Ausência de dados faltantes.

Exemplo: Se no dataset algumas imagens não têm rótulo (sem dizer se é gato ou cachorro)



Preparação de Dados: Qualidade dos Dados

Accuracy (Acurácia)

O dado representa corretamente a realidade.

Ex. Se uma imagem é de um gato, mas no dataset está rotulada como cachorro, temos um problema de acurácia. Isso gera erros no treinamento do modelo.

Completeness (Completeness)

Ausência de dados faltantes.

Exemplo: Se no dataset algumas imagens não têm rótulo (sem dizer se é gato ou cachorro)



Consistency (Consistência)

Os dados não apresentam contradições entre si.

Exemplo: Um registro diz que o arquivo "img_001.jpg" é cachorro, mas em outro arquivo auxiliar (CSV de metadados) ele aparece como gato. Isso é uma inconsistência.

Preparação de Dados: Qualidade dos Dados

Accuracy (Acurácia)

O dado representa corretamente a realidade.

Ex. Se uma imagem é de um gato, mas no dataset está rotulada como cachorro, temos um problema de acurácia. Isso gera erros no treinamento do modelo.

Completeness (Completeness)

Ausência de dados faltantes.

Exemplo: Se no dataset algumas imagens não têm rótulo (sem dizer se é gato ou cachorro)

Consistency (Consistência)

Os dados não apresentam contradições entre si.

Exemplo: Um registro diz que o arquivo "img_001.jpg" é cachorro, mas em outro arquivo auxiliar (CSV de metadados) ele aparece como gato. Isso é uma inconsistência.



Validity (Validade)

Os dados obedecem às regras e formatos esperados.

Exemplo: Se a coluna "classe" deveria conter apenas "gato" ou "cachorro", mas aparece "elefante" ou valores nulos, os dados não são válidos.

Preparação de Dados: Qualidade dos Dados

Accuracy (Acurácia)

O dado representa corretamente a realidade.

Ex. Se uma imagem é de um gato, mas no dataset está rotulada como cachorro, temos um problema de acurácia. Isso gera erros no treinamento do modelo.

Completeness (Completeness)

Ausência de dados faltantes.

Exemplo: Se no dataset algumas imagens não têm rótulo (sem dizer se é gato ou cachorro)

Uniqueness (Unicidade)

Ausência de duplicação de dados.

Exemplo: Se a mesma imagem de um gato aparece várias vezes no dataset, gera redundância e pode enviesar o modelo (ele "aprende mais gato que cachorro").

Consistency (Consistência)

Os dados não apresentam contradições entre si.

Exemplo: Um registro diz que o arquivo "img_001.jpg" é cachorro, mas em outro arquivo auxiliar (CSV de metadados) ele aparece como gato. Isso é uma inconsistência.

Validity (Validade)

Os dados obedecem às regras e formatos esperados.

Exemplo: Se a coluna "classe" deveria conter apenas "gato" ou "cachorro", mas aparece "elefante" ou valores nulos, os dados não são válidos.



Preparação de Dados: Qualidade dos Dados

Accuracy (Acurácia)

O dado representa corretamente a realidade.

Ex. Se uma imagem é de um gato, mas no dataset está rotulada como cachorro, temos um problema de acurácia. Isso gera erros no treinamento do modelo.

Completeness (Completeness)

Ausência de dados faltantes.

Exemplo: Se no dataset algumas imagens não têm rótulo (sem dizer se é gato ou cachorro)

Uniqueness (Unicidade)

Ausência de duplicação de dados.

Exemplo: Se a mesma imagem de um gato aparece várias vezes no dataset, gera redundância e pode enviesar o modelo (ele "aprende mais gato que cachorro").

Consistency (Consistência)

Os dados não apresentam contradições entre si.

Exemplo: Um registro diz que o arquivo "img_001.jpg" é cachorro, mas em outro arquivo auxiliar (CSV de metadados) ele aparece como gato. Isso é uma inconsistência.

Validity (Validade)

Os dados obedecem às regras e formatos esperados.

Exemplo: Se a coluna "classe" deveria conter apenas "gato" ou "cachorro", mas aparece "elefante" ou valores nulos, os dados não são válidos.


Timeliness garante que os dados são recentes (sem câmeras antigas) e relevantes (dentro do contexto) para a decisão ou modelo que será construído.



Preparação de Dados: Qualidade dos Dados

Atividade 1: Pesquisar no (UCI, Kaggle ou Physionet) um dataset Estruturado (categórico) para alimentar técnicas de classificação.

Preparação de Dados: Missão dos dados



Preparação de Dados: Processos da Preparação

- ❑ Coleta, download ou upload do dataset
- ❑ Entendimento das Informações básicas (dimensão, característica, rótulos de classe/categoria)
- ❑ Estatística das Informações
- ❑ Visualização
- ❑ Limpeza


Preparação de Dados: Processos da Preparação

- ❑ Coleta, download ou upload do dataset



Preparação de Dados: Processos da Preparação

- Entendimento das Informações básicas (dimensão, característica, rótulos de classe/categoria)



Classes/Categorias
Gato e Cachorro

Características:

orelhinha → mais pontudinha (gato) ou mais caída (cachorro)
bigodinho → mais espetado (gato) ou mais cheinho (cachorro)
focinho → mais achatado (gato) ou mais comprido (cachorro)

Características				Classe	
orelhinha	bigodinho	focinho	classe	1 to 10 of 200 entries	classe_nome
7.496714153011233	4.584629257949586	4.286229888278626	0	gato	
6.861735698828816	5.579354677234641	4.448627621094587	0	gato	
7.6476885381006925	5.65728548347323	4.866440994540222	0	gato	
8.523029856408025	5.197722730778381	4.843041641627923	0	gato	
6.765846625276664	5.838714288333991	2.897864505634327	0	gato	
6.765863043050819	6.404050856814538	3.2497399680679018	0	gato	
8.579212815507391	7.88618590121053	4.412028213766928	0	gato	
7.7674347291529084	6.174577812831839	4.411028760729767	0	gato	
6.530525614065048	6.2575503907227645	4.412038149044839	0	gato	
7.542560043585965	5.925554084233832	7.082185192523777	0	gato	

Preparação de Dados: Processos da Preparação

📄 Estatísticas

Example 01 Find the Mean, Median, Mode, and Range of the data set:

Goals Scored Over the Last 7 Games

1 3 4 6 6 7 8

mean 5
average


mode 6
most common

median 6
middle

range 7
largest - smallest



Measures of Central Tendency, Mean, Median & Mode




Preparação de Dados: Processos da Preparação


Estadísticas

A média mostra o valor “do meio” de um grupo.

A variância e o desvio padrão mostram o quanto os valores ficam afastados dessa média.



usando o desvio padrão, temos uma maneira “padrão” de saber o que é normal e o que é muito grande ou muito pequeno.




Variance

$$\begin{aligned}\sigma^2 &= \frac{206^2 + 76^2 + (-224)^2 + 36^2 + (-94)^2}{5} \\ &= \frac{42436 + 5776 + 50176 + 1296 + 8836}{5} \\ &= \frac{108520}{5} \\ &= 21704\end{aligned}$$



Standard Deviation

$$\begin{aligned}\sigma &= \sqrt{21704} \\ &= 147,32... \\ &= 147 \text{ (to the nearest mm)}\end{aligned}$$




Preparação de Dados: Processos da Preparação

Visualização



Preparação de Dados: Processos da Preparação

Visualização




The actual values in a distribution



How a histogram would display the values (rotated)



How a boxplot would display the values



Preparação de Dados: Processos da Preparação

- ❑ Coleta, download ou upload do dataset

Vamos explorar dados Estruturados (categóricos), com características já extraídas e planilhadas

Preparação de Dados: Coleta, download ou upload

Baixaremos um dataset disponível no sklearn.datasets
O Iris dataset



E usaremos essas bibliotecas
para explorar os dados



Preparação de Dados: Explorando o dataset Iris

Entendimento das Informações (características, rótulos)



[Clique para acessar o Notebook 1 no Google Colab](#)

iris setosa



petal sepal

iris versicolor




petal sepal

iris virginica



petal sepal

Supervised learning *classification* problem
(using the [Iris flower data set](#))



Training / test data

Features

Labels

Sepal length	Sepal width	Petal length	Petal width	Species
5.1	3.5	1.4	0.2	Iris setosa
4.9	3.0	1.4	0.2	Iris setosa
7.0	3.2	4.7	1.4	Iris versicolor
6.4	3.2	4.5	1.5	Iris versicolor
6.3	3.3	6.0	2.5	Iris virginica
5.8	3.3	6.0	2.5	Iris virginica

150 instâncias de flores iris

4 features: comprimento/largura de sépala e pétala

3 classes: Setosa, Versicolor, Virginica

Problema: Classificação multiclasse

Preparação de Dados: Explorando o dataset Iris

Entendimento das Informações (características, rótulos)



[Clique para acessar o Notebook 1 no Google Colab](#)

INFORMAÇÕES BÁSICAS

=====

Formato: (150, 6)

Colunas: ['sepal length (cm)', 'sepal width (cm)', 'petal length (cm)', 'petal width (cm)', 'target', 'species']

Primeiras linhas:

	sepal length (cm)	sepal width (cm)	petal length (cm)	petal width (cm)	\
0	5.1	3.5	1.4	0.2	
1	4.9	3.0	1.4	0.2	
2	4.7	3.2	1.3	0.2	
3	4.6	3.1	1.5	0.2	
4	5.0	3.6	1.4	0.2	

	target	species
0	0	Setosa
1	0	Setosa
2	0	Setosa
3	0	Setosa
4	0	Setosa


Preparação de Dados: Explorando o dataset Iris

Entendimento das Informações (características, rótulos)




[Clique para acessar o Notebook 1 no Google Colab](#)

VISUALIZAÇÃO DAS FEATURES



BOXPLOTS POR ESPÉCIE



Preparação de Dados: Explorando o dataset Iris

Entendimento das Informações (características, rótulos)



[Clique para acessar o Notebook 1 no Google Colab](#)


CORRELAÇÕES

Matriz de correlação:


```
sepal length (cm)  sepal width (cm)  petal length (cm)  \
sepal length (cm)    1.000         -0.118         0.872
sepal width (cm)     -0.118         1.000         -0.428
petal length (cm)     0.872         -0.428         1.000
petal width (cm)      0.818         -0.366         0.963
```

```
sepal length (cm)  petal width (cm)
sepal length (cm)    0.818
sepal width (cm)     -0.366
petal length (cm)     0.963
petal width (cm)      1.000
```

Correlações entre Features



SCATTER PLOTS




Preparação de Dados: Explorando o dataset Iris




[Clique para acessar o Notebook 1 no Google Colab](#)

O entendimento do dataset, suas características extraídas, compreendidas são a entrada para uma Técnica de ML

Supervised learning *classification* problem
(using the [Iris flower data set](#))



Training / test data				
Features				Labels
Sepal length	Sepal width	Petal length	Petal width	Species
5.1	3.5	1.4	0.2	Iris setosa
4.9	3.0	1.4	0.2	Iris setosa
7.0	3.2	4.7	1.4	Iris versicolor
6.4	3.2	4.5	1.5	Iris versicolor
6.3	3.3	6.0	2.5	Iris virginica
5.8	3.3	6.0	2.5	Iris virginica



Preparação de Dados

Atividade 2: Desenvolver um notebook code implementando os passos de Preparação de Dados de um processo de desenvolvimento de modelo de ML

Preparação de Dados: Coleta, download ou upload


Baixaremos um dataset disponível no seaborn
O Penguins dataset

```
['anagrams',  
'anscombe',  
'attention',  
'brain_networks',  
'car_crashes',  
'diamonds',  
'dots',  
'exercise',  
'flights',  
'fmri',  
'gammas',  
'geyser',  
'iris',  
'mpg',  
'penguins',  
'planets',  
'tips',  
'titanic']
```



seaborn

E usaremos essas bibliotecas
para explorar os dados



NumPy



seaborn

Pandas




matplotlib

Preparação de Dados: Explorando o dataset Penguins



[Clique para acessar o Notebook 2 no Google Colab](#)



Note: In the raw data, bill dimensions are recorded as “culmen length” and “culmen depth”. The culmen is the dorsal ridge atop the bill.

344 instâncias de pinguins

7 features: espécie, ilha, comprimento/profundidade do bico, massa corporal, sexo

3 espécies: Adelie, Chinstrap, Gentoo

Dados reais coletados por Dr. Kristen Gorman



INFORMAÇÕES BÁSICAS

=====

Formato: (333, 7)

Colunas: ['species', 'island', 'bill_length_mm', 'bill_depth_mm', 'flipper_length_mm', 'body_mass_g', 'sex']

Primeiras linhas:

	species	island	bill_length_mm	bill_depth_mm	flipper_length_mm	\
0	Adelie	Torgersen	39.1	18.7	181.0	
1	Adelie	Torgersen	39.5	17.4	186.0	
2	Adelie	Torgersen	40.3	18.0	195.0	
4	Adelie	Torgersen	36.7	19.3	193.0	
5	Adelie	Torgersen	39.3	20.6	190.0	

Preparação de Dados: Processos da Preparação


- ❑ Coleta, download ou upload do dataset

Vamos explorar dados de imagens, que as características ainda não foram extraídas

Imagens são dados não-estruturados que requerem técnicas específicas de processamento e análise.

Preparação de Dados: Coleta, download ou upload

Baixaremos um dataset disponível no `tensorflow.keras.datasets`
O MNIST dataset



E usaremos essas bibliotecas
para explorar os dados




Preparação de Dados: Coleta, download ou upload



[Clique para acessar o Notebook 3 no Google Colab](#)

Baixaremos um dataset disponível no `tensorflow.keras.datasets`
O MNIST dataset



Total de imagens: 70000

Tamanho das imagens: 28x28 pixels



Número de classes: 10

Preparação de Dados: Coleta, download ou upload



[Clique para acessar o Notebook 3 no Google Colab](#)

Um dataset de imagem, tipicamente é a entrada de um Aprendizado Profundo (DL)



Processo de Desenvolvimento de Modelo de Machine Learning

