
História da Inteligência Artificial e o Caminho até a IA Generativa

Curso de Formação Inicial e Continuada (FIC)
De 1943 ao Estado da Arte · 2026

Autor: Prof. Ramon Mayor Martins, Dr. - IFSC - Área de Telecomunicações - 2026


Sobre Este Curso

- A história da Inteligência Artificial é uma das mais fascinantes da ciência — cheia de grandes ideias, invernos longos, reviravoltas e avanços explosivos.
- Este curso conta essa história do começo ao fim, com ênfase especial no capítulo mais recente: a IA Generativa.
- Público-alvo: Profissionais, estudantes e entusiastas. Sem pré-requisito de programação ou matemática avançada.

ESTRUTURA — 6 MÓDULOS:

- Módulo 1 — As Raízes: Matemática, Lógica e os Pioneiros (1943–1969)
- Módulo 2 — Os Ciclos: Invernos, Renascimento e Machine Learning (1970–2005)
- Módulo 3 — A Revolução do Deep Learning (2006–2016)
- Módulo 4 — A Era dos Transformers e dos LLMs (2017–2022)
- Módulo 5 — IA Generativa: o Clímax dessa Jornada (2014–2024)
- Módulo 6 — Estado da Arte, Ética e o Futuro (2024–2026+)

A Jornada em 80 Anos: De Turing ao ChatGPT



MÓDULO 1




As Raízes: Matemática, Lógica e os Pioneiros

1943 – 1969

Os fundamentos matemáticos e computacionais que tornaram possível pensar em máquinas inteligentes

Antes da IA: Os Fundamentos Matemáticos (1913–1950)



- 1913 — Cadeias de Markov: Modelo probabilístico de transições entre estados. Base de reconhecimento de fala e geração de texto.
- 1936 — Máquina de Turing: Alan Turing formaliza o conceito de computação universal: qualquer algoritmo pode ser descrito e executado por uma máquina abstrata.
- 1943 — Neurônio Artificial (McCulloch & Pitts): Primeiro modelo matemático do neurônio biológico. Base conceitual de todas as redes neurais modernas.



Estes fundamentos mostram que a IA nasceu da interseção entre matemática, lógica e engenharia — não de uma única ideia.

Antes da IA: Os Fundamentos Matemáticos (1913–1950)

- 1948 — Teoria da Informação (Shannon): Claude Shannon quantifica a informação matematicamente. Pilar da computação, telecomunicações e IA.
- 1950 — Teste de Turing: 'Computing Machinery and Intelligence' — Turing propõe: uma máquina pode imitar um humano de forma indistinguível?
- 1951 — SNARC: Primeira Rede Neural Física — Minsky e Edmonds constroem com relês elétricos a primeira rede neural com 40 neurônios.



💡 Estes fundamentos mostram que a IA nasceu da interseção entre matemática, lógica e engenharia — não de uma única ideia.

O Nascimento Oficial da IA — Dartmouth, 1956

- A Conferência de Dartmouth (verão de 1956): John McCarthy, Marvin Minsky, Claude Shannon e Nathaniel Rochester reuniram-se para propor uma ideia revolucionária.

A proposta fundadora:

'Todo aspecto do aprendizado ou qualquer característica da inteligência pode ser descrito com precisão suficiente para que uma máquina o simule.'

O que nasceu ali:

- **O termo oficial 'Inteligência Artificial' — cunhado por McCarthy**
- A IA como campo científico autônomo
- As metas fundadoras: linguagem, raciocínio, aprendizado, criatividade
- A consequência imediata: Financiamentos generosos, pesquisadores entusiasmados, e a crença de que a IA humana seria replicada em poucas décadas.



Dartmouth College, Hanover, NH, EUA | Participantes: McCarthy, Minsky, Shannon, Rochester

Os Primeiros Avanços e os Primeiros Limites (1957–1969)

- 1957 — Perceptron (Rosenblatt): Primeira rede neural treinável — aprende pelos dados. Classificador binário inspirado no neurônio biológico. Funcionou para padrões simples, mas manchetes prometiam demais.
- 1958 — LISP (**McCarthy**): Linguagem criada para manipular símbolos lógicos. Dominante em pesquisa de IA por 30 anos. **Quem cunhou o termo Inteligência Artificial.**
- 1959 — Machine Learning (Arthur Samuel): Programa de damas que aprende com experiência e passa a vencer seu criador. Samuel cunha o termo 'Machine Learning'.

1969 — O Fim do Primeiro Ciclo:

- Minsky & Papert provam matematicamente que o Perceptron não resolve problemas não-lineares
 - Financiamentos cortados. Pesquisadores abandonam o campo.
 - Início do 1º Inverno da IA (1969–1980)
- Por que o entusiasmo foi exagerado? Computadores 10.000× menos potentes que o necessário. Sem dados suficientes para treinar modelos.



MÓDULO 2

Os Ciclos: Invernos, Renascimento e Machine Learning

1970 – 2005

A IA morre e renasce — sistemas especialistas, backpropagation e a era dos dados

Sistemas Especialistas e o 2º Inverno (1970–1993)

Sistemas Especialistas (1970–1987):


- MYCIN: diagnóstico de infecções por regras 'se-então'
- DENDRAL: identificação de moléculas orgânicas
- R1/XCON (DEC): economizou milhões configurando computadores
- Sucesso real, mas frágeis: falham fora do domínio treinado

1986 — Backpropagation (Rumelhart, Hinton, Williams):

- Algoritmo que treina redes multicamadas calculando gradientes. Abre caminho para o Deep Learning moderno.

O 2º Inverno da IA (1987–1993):

- Mercado de sistemas especialistas colapsa — manutenção impossível
- Lisp machines perdem para PCs convencionais
- Agências de financiamento cortam verbas novamente




🔄 **A lição dos dois invernos: A IA avança em ciclos de hype → decepção → refinamento → novo salto.**

Machine Learning Clássico e o Renascimento (1989–2005)

- 1989 — CNNs de LeCun: Redes convolucionais aplicadas a dígitos manuscritos. Usadas por bancos americanos para ler cheques.
- 1995 — SVM e Random Forest: Support Vector Machine: separação ótima de classes com maior margem. Random Forest: ensemble de árvores de decisão — simples e poderoso.
- 1997 — LSTM (Hochreiter & Schmidhuber): Long Short-Term Memory: resolve gradiente desvanecente em RNNs. Dominou NLP por 20 anos.
- 1997 — Deep Blue vence Kasparov: IBM Deep Blue derrota o campeão mundial de xadrez. Marco cultural: pela primeira vez, máquina supera humano em tarefa cognitiva de prestígio.

2001–2005 — A Era dos Dados Começa:

- Internet cresce — petabytes de texto, imagens e interações
- Wikipedia, blogs, redes sociais criam corpora sem precedentes
- O combustível estava pronto. Faltavam os motores.



 O combustível (dados) estava pronto. Faltavam os motores (GPUs + algoritmos).

MÓDULO 3

A Revolução do Deep Learning

2006 – 2016

Quando dados, GPUs e algoritmos se encontraram — e a IA nunca mais foi a mesma

O Ressurgimento: Hinton e a Aposta nas Redes Profundas (2006–2012)

- 2006 — Geoffrey Hinton não desistiu: Enquanto a comunidade abandonava redes neurais, Hinton publicou técnica de pré-treinamento em camadas que finalmente funcionou com redes profundas.

O que mudou desta vez:

- GPUs da NVIDIA (2007+): paralelismo massivo — 100× mais rápido que CPUs
- Big Data: ImageNet com 1M+ imagens rotuladas
- Algoritmos novos: ReLU, Dropout, Batch Normalization

2012 — AlexNet: o Momento que Mudou Tudo:


- Krizhevsky, Sutskever e Hinton vencem ImageNet com margem de 11 pontos percentuais
- 8 camadas, 60M parâmetros, treinada em 2 GPUs por 6 dias
- Prova definitiva: Deep Learning supera tudo que veio antes
- Impacto imediato: Google, Facebook, Microsoft e Amazon fundam laboratórios de DL. Geoffrey Hinton contratado pelo Google por \$44M.



ImageNet 2012: Erro caiu de ~26% para ~15% — primeira vez que máquina supera humanos em classificação visual em larga escala.

O Ressurgimento: Hinton e a Aposta nas Redes Profundas (2006–2012)

- GPUs da NVIDIA (2007+): paralelismo massivo — 100× mais rápido que CPUs



Fonte: ATRA — Linha do Tempo da

A Explosão das Arquiteturas e Aplicações (2013–2016)

Evolução das CNNs (2013–2015):

- 2013 — ZFNet: visualização dos filtros aprendidos
- 2014 — VGGNet: mais profundo, filtros 3×3
- 2014 — GoogLeNet/Inception: eficiência computacional
- 2015 — ResNet: 152 camadas com conexões residuais
- 2016 — AlphaGo derrota Lee Sedol: DeepMind combina Deep Learning + Monte Carlo Tree Search. Vence o campeão mundial de Go — jogo considerado muito complexo para máquinas.

Aplicações que se tornaram reais:

- Visão computacional: detecção de objetos, rostos, cenas
- Diagnóstico médico por imagem (radiologia, dermatologia)
- Reconhecimento de voz: Siri, Alexa, Google Assistant
- Veículos autônomos: redes profundas para percepção
- NLP começa a mudar: Word2Vec (2013), Seq2Seq (2014). Google substitui tradução estatística por redes neurais (2016).



🎯 **AlphaGo: marco cultural — máquina supera humano em jogo de complexidade exponencial.**

Deep Learning em Números

60M

Parâmetros do AlexNet (2012)

152

Camadas do ResNet (2015)

1M+

Imagens no ImageNet

100×

GPU vs CPU em DL

2012

Ano da virada definitiva

-11pp

Queda no erro do ImageNet

MÓDULO 4

A Era dos Transformers e dos LLMs

2017 – 2022

'Attention is All You Need' — a arquitetura que mudou tudo

'Attention is All You Need' — 2017

- O artigo mais influente da década em ML: Vaswani et al. (Google Brain), 2017. Propôs arquitetura radicalmente diferente para processar sequências.

O problema que resolveu:

- RNNs e LSTMs processam palavra por palavra — lento e difícil de paralelizar
- Perdem contexto em sequências longas

A solução: Mecanismo de Atenção (Self-Attention)

- Cada palavra 'olha' para todas as outras ao mesmo tempo
- Processamento paralelo: muito mais rápido em GPUs/TPUs
- Captura dependências em qualquer distância

Componentes do Transformer:

- Multi-Head Attention + Positional Encoding
- Feed-Forward Layers + Layer Normalization
- Base de BERT, GPT, Llama, Gemini, Claude — todos.

 **ANTES (RNN/LSTM): Sequencial, lento, perde contexto distante. COM TRANSFORMER: Todas as palavras ao mesmo tempo. Qualquer par pode se 'atender'.**

BERT, GPT e a Corrida pelos LLMs (2018–2021)

- 2018 — BERT (Google): Bidirecional: lê texto dos dois lados simultaneamente. Masked Language Model: aprende a completar palavras mascaradas. Bateu o estado da arte em 11 benchmarks de NLP de uma vez.

2018–2019 — GPT-1 e GPT-2 (OpenAI):

- GPT-1: 117M parâmetros — geração via decoder
- GPT-2: 1,5B — tão convincente que OpenAI atrasou o lançamento
- Prova: mais parâmetros + mais dados = melhor geração



2020 — GPT-3: O Grande Salto:

- 175 bilhões de parâmetros — 100× maior que GPT-2
- Few-shot e Zero-shot learning
- Escreve código, ensaios, poesia, traduz, resume
- Custo de treinamento: ~\$12 milhões
- Scaling Laws confirmadas (Kaplan et al., 2020): Performance melhora previsivelmente com escala. Lança a corrida: PaLM (540B), Gopher (280B)...



Scaling Laws: Quem treinar o maior modelo ganha? (Spoiler: não exatamente — qualidade dos dados também importa.)

A Explosão dos Parâmetros: Scaling Laws

117M

GPT-1 (2018)

1.5B

GPT-2 (2019)

175B

GPT-3 (2020)

540B

PaLM — Google (2022)

1T+

Modelos MoE (2023+)

10.000×

Crescimento em 5 anos

MÓDULO 5

IA Generativa: o Clímax dessa Jornada

2014 – 2024

GANs, Difusão, LLMs e o mundo que nunca mais voltou ao que era

O Que é IA Generativa? (e por que é diferente de tudo antes)

A diferença fundamental:

- IA discriminativa (toda história anterior): recebe dado → classifica ou prediz. ('Esse e-mail é spam?')
- IA generativa: aprende a distribuição dos dados e cria conteúdo novo. ('Escreva um e-mail sobre X.')
- Shift radical: de análise para criação.

As três grandes famílias de modelos generativos:

- GANs (2014): gerador vs. discriminador em competição adversarial
- VAEs (2013): codificam dados em espaço latente comprimido e geram variações
- Modelos de Difusão (2020): destroem dados com ruído e aprendem a desfazer o processo
- LLMs / Transformers (2017+): geração autoregressiva em escala massiva
- Por que agora? A IA Generativa não surgiu do nada. É o resultado direto de 80 anos de acumulação.



Cada módulo deste curso foi um tijolo nessa construção: neurônios artificiais → backprop → deep learning → transformers → escala + dados.

GANs — O Jogo que Ensinou Máquinas a Criar (2014)

- Ian Goodfellow et al. — 2014: Ideia nascida numa discussão de bar: dois modelos competem entre si para que ambos fiquem melhores.

O mecanismo adversarial:

- Gerador (G): cria imagens falsas tentando enganar o discriminador
- Discriminador (D): tenta detectar se são reais ou geradas
- Treinamento simultâneo: ambos melhoram em paralelo
- Analogia: falsificador vs. detetive
- O falsificador melhora ao tentar enganar o detetive. O detetive melhora ao detectar falsificações. Resultado: imagens indistinguíveis do real.

Aplicações reais:

- StyleGAN (NVIDIA): faces fotorrealistas sintéticas
- Deepfakes: transferência de rosto em vídeos
- Síntese de imagens médicas para treinar modelos

 Função de perda: $\min_G \max_D V(D, G)$ | Evolução: GAN → DCGAN → CycleGAN → StyleGAN → StyleGAN3

Modelos de Difusão: A Revolução das Imagens (2020–2022)

- A ideia inspirada na física: O modelo aprende a destruir uma imagem adicionando ruído gaussiano gradativamente — e depois aprende a reverter esse processo.

Processo em duas fases:

- Fase forward: imagem real → ruído puro (T passos)
- Fase reversa: ruído puro → nova imagem (U-Net denoising)

Por que superaram as GANs?

- Treinamento estável: sem o jogo adversarial instável
- Mais diversidade: não sofrem de mode collapse
- Condicionamento por texto (CLIP): revolução text-to-image

Os modelos que mudaram o mundo (2022):

- DALL-E 2 (OpenAI): fotorrealismo a partir de texto
- Stable Diffusion (Stability AI): open-source — democratizou
- Midjourney: qualidade artística impressionante



🎨 CLIP conecta texto e imagem: 'Astronauta em Marte' → [Imagem gerada]

ChatGPT e o Momento de Ruptura (Novembro de 2022)

- InstructGPT → ChatGPT: OpenAI aplica RLHF ao GPT-3.5 — Reinforcement Learning from Human Feedback.

Como o RLHF funciona:

1. Modelo gera respostas variadas para cada prompt
 2. Avaliadores humanos ranqueiam as melhores
 3. Reward model aprende as preferências humanas
 4. Política ajustada via RL para maximizar recompensa
- Resultado: Segue instruções de forma confiável. Respostas úteis, inofensivas e honestas.


O Produto de IA mais Rápido da História:

- 1 milhão de usuários: 5 dias (Netflix levou 3,5 anos)
- 100 milhões de usuários: 2 meses
- O efeito cascata: Google lança Bard → Microsoft integra ao Bing e Office (Copilot) → Meta libera LLaMA → Anthropic lança Claude → Corrida global por LLMs




ChatGPT provou que IA generativa não é apenas técnica — é produto. É experiência. É mudança de paradigma.

IA Generativa: da GAN ao Estado da Arte (2014–2026)



IA Generativa: da GAN ao Estado da Arte (2014–2026)



MÓDULO 6

Estado da Arte, Ética e o Futuro

2024 – 2026+

Onde estamos agora, os desafios reais e para onde vamos

Os Modelos que Lideram o Mundo em 2025–2026

- GPT-5 (OpenAI): Multimodal nativo: texto, imagem, áudio, vídeo. Melhor em raciocínio e codificação.
- Gemini 3 Pro (Google): Forte em raciocínio e conhecimento — GPQA Diamond: 94.3%. Contexto de 2 milhões de tokens.
- Claude Opus 4.8 (Anthropic): Forte em raciocínio e código — SWE-bench Pro: 69.2%. Foco em segurança e instruções complexas.

Modelos Open-Source:

- Llama 5 (Meta): Open-weights, roda localmente sem cloud via Ollama.
- DeepSeek-R1 (China, jan/2025): Competitivo com GPT-4 em matemática e código. MIT License — gratuito. Causou queda de ações de IA nos EUA.
- A brecha se fechou: Em 2024, open-source estava muito atrás. Em 2026, a diferença é mínima em muitas tarefas.



A corrida por modelos de ponta é global e acelerada. Open-source está alcançando rapidamente.

Os Modelos que Lideram o Mundo em 2025–2026



🌐 A corrida por modelos de ponta é global e acelerada. Open-source está alcançando rapidamente.

IA Generativa no Mundo — 2025/2026

900M

Usuários semanais do ChatGPT (2026)

88%

Organizações usando IA (2026)

1/6

Pessoas no mundo usam IA generativa

94.3%

GPQA Diamond — Gemini 3 Pro

70%

Líderes em saúde adotando IA generativa

+35%

Produtividade com GitHub Copilot

Desafios Reais: Ética, Limites e Regulamentação

- Alucinações: LLMs inventam fatos com confiança. 15–25% das saídas contêm erros factuais (Dialnet, 2025).
- Viés algorítmico: Modelos refletem preconceitos históricos: raça, gênero, cultura, idioma.
- Custo ambiental: Treinamento de GPT-4: ~\$100M e consumo energético equivalente a cidades inteiras.
- Deepfakes e desinformação: Vídeos e imagens falsos convincentes. Risco real para democracia e jornalismo.
- Direitos autorais: Modelos treinados em obras sem consentimento. Disputas legais em curso no mundo.
- EU AI Act (2024): Primeiro marco legal global para IA. Classifica IA por risco: alto, médio, baixo. Transparência obrigatória em aplicações de alto risco.

 **Tecnologia avança mais rápido que a regulamentação. A ética não é opcional — é infraestrutura.**

O Futuro: Para Onde Vai a IA? (2026–2030)

AGI — a questão que divide a comunidade:

- Inteligência Artificial Geral ainda é hipotética, mas a fronteira entre IA estreita e AGI está se diluindo. Modelos como GPT-5 realizam tarefas que exigiam anos de especialização humana.

Tendências projetadas para 2026–2030:

- Multimodalidade universal: texto, imagem, áudio, vídeo, código e dados científicos integrados
- Computação quântica + IA: primeiras integrações em 2025/2026
- Democratização radical: IA em dispositivos pessoais sem cloud (Edge AI como norma)
- Nobel de Química 2024 foi sobre IA (AlphaFold): ciência acelerada
- IA como infraestrutura — invisível e onipresente, como a internet hoje

A pergunta que fica:

- Oitenta anos separaram o neurônio de McCulloch & Pitts (1943) do ChatGPT (2022). Que mundo teremos daqui a 80 anos — ou a 8?



O futuro não é previsível, mas é construível. Cada decisão ética e técnica de hoje molda o amanhã.

Obrigado!

Ferramentas para Explorar:

ChatGPT (chatgpt.com) · Claude (claude.ai) · Gemini (gemini.google.com)
Perplexity AI (perplexity.ai) · Hugging Face (huggingface.co)
Deep Learning Book (deeplearningbook.org) · Papers with Code (paperswithcode.com)

Prof. Ramon Mayor Martins, Dr. - IFSC - Área de Telecomunicações - 2026